

Entregable 1: Reto

AUTHORS

Diego Vértiz Padilla

José Ángel Govea García

Augusto Ley Rodríguez

Daniel Alberto Sánchez Fortiz



[Repositorio](#)

Introduccion

Contexto

Hoy en día, las empresas trabajan con varios equipos al mismo tiempo, cada uno enfocado en proyectos distintos y con diferentes clientes. Coordinar todo eso no es tarea fácil. Se necesita conocer bien las habilidades y la experiencia de cada persona, pero también entender su nivel de motivación y compromiso día a día. Además, cuando los equipos están en distintas ubicaciones, con especialidades diferentes y cierta rotación de personal, es más complicado tener una visión completa de cómo está funcionando todo el conjunto.

Objetivo(s)

Se recibirá información sobre el trabajo de múltiples equipos en diversos proyectos y con distintos clientes. Los datos incluirán el ID de empleado, la experiencia técnica, el nivel de seniority y los detalles del proyecto, como el equipo asignado, el nombre del proyecto y el cliente correspondiente. Asimismo, se proporcionarán métricas de participación que abarcan indicadores de motivación y engagement con granularidad diaria, registrando la actividad de cada persona durante seis meses.

Justificación

Analizar la forma en que trabajan los equipos se ha vuelto clave para mejorar tanto los resultados como el ambiente laboral. Ya no basta con medir solo si se cumplen los objetivos o si un proyecto termina a tiempo; también importa entender qué impulsa a las personas a rendir mejor, qué factores las desmotivan y cómo se pueden equilibrar las cargas de trabajo. A través de los datos, las empresas pueden detectar patrones, como bajones de rendimiento o falta de participación, antes de que se conviertan en problemas mayores. Además, este tipo de análisis permite aprovechar mejor el talento interno, asignando tareas de acuerdo con las

fortalezas y experiencia de cada colaborador. De esta manera, se pueden tomar decisiones más acertadas, no solo desde la productividad, sino también desde el bienestar del equipo. En pocas palabras, entender los datos del comportamiento laboral ayuda a crear un entorno más equilibrado, eficiente y humano.

Descripción de los datos

Contexto de los datos

El conjunto de datos contiene 11,366 registros (filas) y 17 variables (columnas). Cada fila representa la información de una persona trabajadora en un momento específico del tiempo, registrando aspectos relacionados con su puesto, proyecto, área, cliente y nivel de engagement (compromiso) dentro de la empresa.

El dataset se utiliza principalmente para analizar patrones de compromiso laboral y su relación con características del proyecto, equipo, líder, área o fechas.

Estructura

Variable	Tipo de dato	Significado
Date	Objeto	Es la fecha en la que registraron los datos.
Email	Objeto	El email de la persona
Name	Objeto	El nombre de la persona
Position	Objeto	Puesto de la persona
Seniority	Objeto	Rango de la persona
Location	Objeto	Lugar en donde trabaja
Studio	Objeto	El área donde trabaja la persona
Client	Objeto	Cliente del proyecto en el que trabaja la persona
Client Tag	Objeto	ID de la persona
Project	Objeto	Nombre del proyecto en el que trabaja la persona

Project Tag	Objeto	ID del proyecto
Team Name	Objeto	Nombre del equipo en el cual está la persona
Engagement	float	Nivel de compromiso de la persona en su proyecto
Email Leader	Objeto	Email del líder de la persona
Year	int	Año en el que se registró el dato
Month	int	Mes en el que se registró el dato
Day	int	Día en el que se registró el dato

Calidad de los datos

La única variable que cuenta con datos faltantes es la de Email Leader, la tiene 1.140 datos nulos. Previo a realizar un analisis profundo en el conjunto de datos, parece que esta variable no sera importante para el modelo.

Resumen estadístico

La siguiente tabla muestra las estadísticas descriptivas de las 4 variables numéricas:

Estadístico	Engagement	Year	Month	Day
mean	2.995	2023	3.54	15.87
std	1.0054	0	1.72	8.75
min	0.0	2023	1.0	1.0
25%	2.52	2023	2.0	9.0
50%	3.05	2023	4.0	16.0
75%	3.60	2023	5.0	23.0
max	5.00	2023	6.0	31.0

Metodologia

Limpieza de datos

Para garantizar la calidad del análisis y evitar redundancias dentro del conjunto de datos, se llevo a cabo un proceso de limpieza de datos. Las acciones realizadas fueron las siguientes:

1. Eliminación de las columnas 'Year', 'Month' y 'Day'

Debido a que ya contamos con la información de año, mes y día en la columna 'Date' estas columnas se volvieron redundantes. Por lo tanto, se eliminaron para evitar duplicidad de la información.

2. Estandarización de la columna 'email leader'

La columna 'Email Leader' fue renombrada como 'Name Leader', ya que su contenido fue transformado para alinearse con este nuevo significado. Se extrajo únicamente el nombre del líder, eliminando el dominio del correo electrónico. Esto permitió obtener un identificador más claro y adecuado para análisis posteriores.

Durante el proceso, se detectó la presencia de valores nulos en esta columna. Tras revisar los casos específicos, se identificó que los valores faltantes correspondían a project managers o líderes de proyecto. Debido a esto, se decidió imputar los valores faltantes utilizando el propio nombre del individuo, garantizando consistencia en la columna.

3. Eliminación de columnas redundantes

Las columnas Client y Project almacenan la misma información que Client Tag y Project Tag. Para evitar duplicación, ambas columnas fueron eliminadas, conservando únicamente los identificadores únicos que representan a cada cliente y proyecto.

4. Detección de valores inválidos, faltantes y duplicados

- Valores faltantes (NaN): se confirmó que, salvo el caso mencionado en la columna del líder, no existían nulos adicionales en el dataset.
- Valores inválidos: se verificó que todas las variables cumplieran con su dominio esperado, en particular la columna 'Engagement', sin detectar valores fuera de rango.
- Duplicados: se comprobó que el conjunto de datos no contenía registros duplicados.

Transformaciones

1. Conversión de fecha a tipo datetime

La variable 'Date' originalmente se encontraba en formato de texto (string). Por lo que, decidimos convertir la variable a un timestamp, lo que nos facilita realizar un análisis temporal.

2. Discretización de la variable Engagement

Con el objetivo de transformar la variable continua 'Engagement' en una versión discreta, se creó una nueva columna llamada 'Engagement Group'. El proceso aplicado fue:

- Los valores iguales a 0 se mantuvieron como 0, dado que este valor representa los días en los que el empleado está de vacaciones.
- Para los valores mayores a 0, se aplicó una discretización mediante quintiles, dividiendo la distribución de Engagement en cinco segmentos de tamaño similar.
- A cada quintil se le asignó una etiqueta del 1 al 5, representando niveles crecientes.

EDA (exploratory data analysis)

El Análisis Exploratorio de Datos permitió comprender la estructura general del conjunto de datos, validar su calidad y detectar patrones relevantes asociados al comportamiento del Engagement. A continuación, se presentan los principales hallazgos obtenidos a partir de visualizaciones.

1. Composición y estructura del dataset

El dataset contiene 11,366 registros que representan información diaria de empleados, incluyendo variables de identificación, atributos laborales, asignación a cliente y proyecto, localización, estudio al que pertenecen y su nivel de Engagement. La mayoría de las variables son categóricas, mientras que Engagement es la principal variable numérica continua.

2. Calidad del dato: valores faltantes, duplicados e inválidos


El EDA confirma que:

- No existen valores faltantes en ninguna columna del dataset
- No se encontraron registros duplicados.
- No se detectaron valores inválidos en Engagement ni en otras columnas; todas las variables respetan su dominio esperado.

3. Distribución temporal

La distribución temporal de los registros indica que el dataset cubre todo

el periodo sin huecos evidentes, aunque la cantidad de registros por intervalo de tiempo varía de forma apreciable.



Distribución temporal de los registros

4. Distribución de variables categóricas

El EDA reveló patrones importantes en la composición laboral:

- En Position, la mayor proporción de empleados pertenece a roles técnicos. Destacan Software Developer (36.6%) y Test Automation Engineer (12.3%).

Value	Count	Frequency (%)
Software Developer	4164	36.6%
Test Automation Engineer	1403	12.3%
Quality Assurance Tester	1054	9.3%
Project Manager	888	7.8%
Business Analyst	803	7.1%
DevOps Engineer	630	5.5%
Data Analyst	489	4.3%
User Experience Designer	294	2.6%
Visual Designer	294	2.6%
Solutions Architect	286	2.5%
Other values (5)	1061	9.3%

Distribución de la variable Position

- En Studio, Engineering (41.4%) y Quality Engineering (21.6%) concentran más del 60% del personal, reflejando una estructura organizacional centrada en desarrollo y aseguramiento de calidad.

Value	Count	Frequency (%)
Engineering	4705	41.4%
Quality Engineering	2457	21.6%
Cloud Ops	1052	9.3%
Product	935	8.2%
Delivery	888	7.8%
Data	741	6.5%
Design	588	5.2%

Distribución de la variable Studio

- En Client Tag, los clientes EDUSYS, EBEPRI y TECNVS representan más del 80% de la asignación total.

Value	Count	Frequency (%)
EDUSYS	3719	32.7%
EBEPRI	3027	26.6%
TECNVS	2431	21.4%
GWID01	1181	10.4%
HSTGIE	1008	8.9%

Distribución de Client Tag

- En Project Tag, proyectos como CATPRO y NEXDEV superan el 20% de participación cada uno, lo cual evidencia la existencia de proyectos grandes con muchos empleados asignados.

Value	Count	Frequency (%)
CATPRO	2450	21.5%
NEXDEV	2431	21.4%
VGRDIN	1269	11.2%
ATLINT	1181	10.4%
STYPRJ	1135	10.0%
ODYOST	1009	8.9%
HOREXP	1008	8.9%
ECOSYS	883	7.8%


Distribución de Project Tag

Estos patrones permiten contextualizar el Engagement según áreas, clientes y proyectos dominantes dentro de la organización.

5. Distribución del Engagement

El histograma de Engagement muestra:

- Una concentración principal entre valores de 2.5 y 4, con forma aproximadamente normal.
- Un grupo significativo con valor 0, correspondiente a días de vacaciones o ausencia de actividad laboral, lo cual justifica su exclusión de análisis cuantitativos directos.



Histograma de la variable Engagement

6. Matriz de correlación

La matriz de correlación entre variables codificadas indica:

- Engagement no presenta correlaciones fuertes con ninguna variable

laboral, indicando que su comportamiento no depende linealmente de atributos como posición, cliente o ubicación.

- Existen correlaciones moderadas entre Position, Seniority y Studio, lo cual refleja la estructura natural de roles dentro de la organización.
- Client Tag, Project Tag y Team Name forman un bloque altamente correlacionado, evidenciando una relación jerárquica cliente, proyecto, equipo.
- Leader Name no muestra correlación significativa con otras variables, sugiriendo que la asignación de líderes no sigue un patrón estructural específico.
- La correlación perfecta entre Engagement y Engagement Group confirma que la discretización en quintiles se aplicó correctamente y preserva la estructura original de la variable.



Matriz de correlación entre variables

7. Análisis de nulos por columna



A simple visualization of nullity by column.

Visualización de nulidad por columna

El análisis gráfico de nulidad muestra que todas las columnas contienen 11,366 registros completos, con la única excepción ya corregida en Leader Name.